

LLM은 새로운 개념을 어떻게 학습하는가: 공식 중심 설명과 스토리 중심 설명의 효과 비교

작성자: 정성원 작성일: 2026년 9월 22일

초록

대규모 언어 모델(LLM)이 교육 분야에서 활용되면서, LLM이 새로운 개념을 학습할 때 어떤 설명 방식이 효과적인지는 중요한 질문이 되었다. 본 연구는 LLM의 사전지식을 차단하기 위해 가상의 최적화 알고리즘(Wave Descent)을 개발하고, 공식 중심 설명과 스토리 중심 설명의 효과를 비교하였다. ChatGPT, DeepSeek, Gemini를 대상으로 총 30회 실험을 수행한 결과, 가설이 예측한 응용 문제에서는 천장 효과로 인해 자극 간 차이를 검증하지 못하였다. 그러나 탐색적 분석에서 재설명과 비유 생성에서는 스토리 중심 설명이 더 높은 점수를 보였다. 다만 DeepSeek에서는 반대 결과가 나타났다. 본 연구는 LLM의 개념 학습 메커니즘을 탐색하였다는 점에서 의의가 있으며, 결과를 사람 학습자에게 일반화하려면 추가 연구가 필요하다.

1. 서론

대규모 언어 모델(LLM)은 교육 분야에서 새로운 학습 도구로 주목받고 있다. 최근 대학 수업에서 학생들은 과제 수행과 개념 이해 과정에서 LLM을 활용하며, 이는 LLM이 교육의 중요한 매개체가 되었음을 시사한다. 특히 머신러닝·딥러닝과 같이 복잡한 개념을 학습할 때 LLM의 역할이 커지고 있다. 그러나 LLM이 새로운 개념을 학습할 때 어떤 설명 방식이 효과적인지는 충분히 연구되지 않았다.

선행 연구는 세 갈래로 요약된다. 첫째, 스토리텔링 학습 효과(Dahlstrom, 2014; Tobler et al., 2024)는 서사가 이해와 전이를 높임을 보였다. 둘째, 비전공자 ML 교육(Sulmont et al., 2019)은 개념적 이해의 중요성을 지적하였다. 셋째, LLM의 형식 민감성(Wei et al., 2022; Sclar et al., 2024)은 프롬프트 형식이 성능에 영향을 줄을 보였다. 그러나 이들 연구는 LLM의 새로운 개념 학습에서 설명 방식의 효과를 직접 검증하지 않았다.

이러한 공백은 두 가지로 구체화된다. 첫째, 스토리텔링 연구는 사람 학습자만 대상으로 하였다. 둘째, LLM 형식 연구는 마크다운·JSON 등 표면적 프롬프트 형식만 다루었고, 설명의 내용적 형식(공식 vs 스토리)은 다루지 않았다. 본 연구는 LLM이 사전지식이 없는 새로운 개념(Wave Descent)을 학습할 때, 설명의 내용적 형식이 미치는 영향을 검증한다. 이는 기존 연구가 다루지 않은 LLM의 개념 학습 메커니즘을 탐색한다는 점에서 의의가 있다.

본 연구의 가설은 다음과 같다: "LLM이 사전지식이 없는 가상의 최적화 알고리즘(Wave Descent)을 학습할 때, 공식 중심 설명보다 스토리 중심 설명에서 응용 문제 점수가 더 높다." 다만 본 연구는 탐색적 연구로서, 응용 문제와 생성 과제(재설명, 비유)를 모두 검증 대상으로 삼았다. 이를 검증하기 위해 ChatGPT, DeepSeek, Gemini를 대상으로 각 10회씩 총 30회 실험을 수행하였다. 각 세션에서 LLM은 자극(공식 또는 스토리)을 읽고, 응용 문제 5문항, 재설명, 비유 생성 과제를 수행하였다. 본 연구는 LLM의 개념 학습 메커니즘을 탐색함으로써, 향후 LLM 기반 교육 도구 설계에 시사점을 제공한다.

2. 방법

2.1 자극물

본 연구는 LLM의 사전지식을 차단하기 위해 가상의 최적화 알고리즘 'Wave Descent'를 사용하였다. 자극 A(공식 중심)는 손실 함수, 파동 함수, 파라미터 등 기술 용어와 갱신식 $\theta_{t+1} = \theta_t - \omega \cdot W(\theta_t)$ 를 포함하는 형식적 설명이다. 자극 B(스토리 중심)는 바다를 항해하는 연구자의 이야기로, 수식 없이 파도·배·항해 등의 비유를 통해 설명한다. 본 실험은 수정 전 자극 B(핵심 정보 5 누락)로 수행되었다. 자극 A는 292자(공백 포함), 자극 B는 179자(공백 포함)로, A가 약 63% 더 길다. 자극의 공정성을 확보하기 위해 제3자 AI(Gemini)에게 공정성 평가를 요청하였다. 평가 결과, 길이(3/5), 정보량(2/5), 난이도(2/5), 편향(3/5)에서 불균형이 확인되었으나, 형식(5/5)에서는 적절한 대조를 이루었다. Gemini는 자극 B에 핵심 정보 5(파동 계수 ω 의 영향)가 누락되었고, 자극 A가 63% 더 길며, 난이도 차이가 크다고 지적하였다.

2.2 피험자

본 연구의 피험자는 ChatGPT, DeepSeek, Gemini이다. 각 LLM에 대해 자극 A와 B를 각 5회씩, 총 10회씩 실험하였다. 전체 실험 횟수는 30회이다. 각 LLM에게 'ML을 처음 접하는 비전공자' 역할을 부여하였다. 프롬프트에는 모르는 단어 목록(최적화, 손실 함수, 파라미터, 경사, 수렴, 학습률, 알고리즘)을 명시하고, 설명이 이해되지 않으면 '이해 불가'라고 답하도록 지시하였다. 본 연구는 설명 방식의 효과가 특정 LLM에 국한되지 않고 재현되는지 검증하기 위해 세 LLM을 선택하였다. 세 LLM은 서로 다른 아키텍처를 가지므로, 결과의 견고성(robustness)을 확인할 수 있다. 다만 DeepSeek과 Gemini는 2단계 문헌 검증에도 참여하였으므로, 이들이 문헌 검증과 피험자 역할을 겸하였다는 한계가 있다. ChatGPT는 문헌 검증에 참여하지 않았다.

2.3 측정 도구

응용 문제는 Wave Descent의 원리를 요리, 산, 다이어트 등 새로운 상황에 적용하는 5문항으로 구성하였다. 각 문항은 1점이며, 총 0~5점이다. 재설명 과제는 Wave Descent를 ML을 모르는 친구에게 설명하듯이 다시 쓰는 것이다. 이때 자극에서 사용한 비유(파도·항해)가 아닌 새로운 비유를 포함하도록 하였다. 채점은 핵심 정보 5개 포함 여부(0~5점)와 새로운 비유 사용 여부(0~1점)로 구성되며, 총 0~6점이다. 재설명의 원래 계획은 0~7점(핵심 정보 5 + 새 비유 1 + 자극 베끼지 않음 1)이었으나, '자극 베끼지 않음' 항목을 적용하지 않아 0~6점으로 조정되었다. 비유 생성 과제는 Wave Descent를 일상생활의 비유로 표현하는 것이다. 채점은 핵심 정보 5개 왜곡 없이 반영 여부(0~5점)와 새로운 비유 생성 여부(0~1점)로 구성되며, 총 0~6점이다. 비유 생성은 채점 부담으로 인해 대표 15개 세션(ChatGPT: A 3회·B 2회, Gemini: A 3회·B 2회, DeepSeek: A 3회·B 2회)만 채점하였다.

2.4 절차

실험은 각 세션마다 새 대화를 시작하여 수행하였다. 프롬프트를 입력하고 응답을 받은 뒤, 응답을 파일로 저장하고 다음 세션을 위해 새 대화를 시작하였다. 새 세션에서 시작한 이유는 이전 대화의 맥락이 다음 응답에 영향을 주는 오염을 방지하기 위함이다. 이를 통해 각 세션의 응답을 독립적으로 확보할 수 있었다. 프롬프트는 다음 요소로 구성하였다: (1) 역할 부여, (2) 모르는 단어 목록, (3) 지시사항(요약·5문항 답변·모르는 단어 목록 작성·이해 불가 시 명시·다양한 관점), (4) 자극(공식 또는 스토리), (5) 응용 문제 5문항, (6) 재설명 과제, (7) 비유 생성 과제. 각 세션의 응답은 텍스트 파일로 저장하였다(chatgpt_1.txt ~ gemini_10.txt, 총 30개).

2.5 채점

채점은 본인이 1차로 수행하고, Claude가 2차로 수행하였다. 이후 두 채점 결과의 일치도를 확인하였다. 대표 5개 세션에 대한 채점 일치도는 1/5(20%)로 낮았다. 이는 '새로운 비유'의 정의와 '핵심 정보 포함' 기준이 모호했기 때문이다. 본 연구는 본인 채점을 최종으로 사용하였으며, 이는 본 연구의 주요 한계이다.

3. 결과

응용 문제(만점 5점)에서 모든 그룹(자극 A, B)이 5.0점 만점을 받았다. 두 자극 간 차이는 없었다. 이는 천장 효과(ceiling effect)로 인해 응용 문제가 자극 간 차이를 검증하지 못했음을 의미한다.

재설명(만점 6점)에서 자극 A(스토리) 평균은 5.6점, 자극 B(공식) 평균은 4.7점으로, A가 B보다 0.9점 높았다. 비유 생성(만점 6점)에서 자극 A(스토리) 평균은 5.2점, 자극 B(공식) 평균은 4.8점으로, A가 B보다 0.4점 높았다.

LLM별로 차이가 나타났다. ChatGPT와 Gemini는 자극 A(스토리)가 자극 B(공식)보다 높았으나, DeepSeek는 자극 B가 더 높았다. 이는 결과의 견고성(robustness)이 약함을 시사한다.

표 1: 응용 문제 (만점 5)

LLM	A (스토리)	B (공식)
ChatGPT	5.0	5.0
Gemini	5.0	5.0
DeepSeek	5.0	5.0
전체	5.0	5.0

표 2: 재설명 (만점 6)

LLM	A (스토리)	B (공식)	차이
ChatGPT	5.6	4.6	+1.0
Gemini	5.8	3.8	+2.0
DeepSeek	5.4	5.6	-0.2
전체	5.6	4.7	+0.9

표 3: 비유 생성 (만점 6, 대표 15개)

LLM	A (스토리)	B (공식)	차이
ChatGPT	5.0	4.0	+1.0
Gemini	5.3	5.0	+0.3
DeepSeek	5.3	5.5	-0.2
전체	5.2	4.8	+0.4

4. 논의

본 연구의 가설은 예측한 응용 문제에서 지지되지 않았으나, 탐색적 분석에서 생성 과제(재설명, 비유)에 스토리가 유리함을 발견하였다. 응용 문제에서는 천장 효과로 인해 자극 간 차이를 검증하지 못했으나, 재설명과 비유 생성에서는 스토리 중심 설명(A)이 공식 중심 설명(B)보다 높은 점수를 보였다. 응용 문제에서 천장 효과가 나타난 원인은 두 가지로 해석된다. 첫째, 응용 문제가 LLM에게 너무 쉬웠다. 둘째, LLM이 두 자극(공식·스토리)을 모두 완벽히 이해하였다. 이는 측정 도구의 난이도 조절 실패로 인한 한계이다.

DeepSeek에서 반대 결과가 나타난 원인은 두 가지로 해석된다. 첫째, DeepSeek는 다른 LLM과 아키텍처가 다르므로, 정보 처리 방식이 다를 수 있다. 둘째, DeepSeek는 문헌 검증에도 참여하였으므로, 이로 인한 편향 가능성이 있다. 이는 결과의 견고성(robustness)이 약함을 시사한다.

채점 일치도가 낮은 원인은 세 가지로 해석된다. 첫째, 채점 기준이 모호하여 본인과 Claude가 다르게 해석하였다. 둘째, 비유의 '새로움'을 판단하는 것이 주관적이었다. 셋째, 핵심 정보 포함 여부도 채점자마다 다르게 평가되었다. 이는 본 연구의 주요 한계이다.

본 연구의 피험자는 LLM이므로 결과를 사람 학습자에게 일반화할 수 없다. LLM은 사람과 정보 처리 방식이 다르며, 이미 ML 지식을 보유하고 있어 '초보자 역할'이 완벽히 수행되지 않았다. 사람은 스토리에 더 몰입하는 반면, LLM은 형식에 덜 민감할 수 있다. 따라서 본 연구 결과를 사람에게 일반화하려면 추가 연구가 필요하다.

본 연구의 한계는 다음과 같다. 첫째, 응용 문제에서 천장 효과가 발생하여 자극 간 차이를 검증하지 못하였다. 둘째, DeepSeek에서 반대 결과가 나타나 결과의 견고성이 약하였다. 셋째, 채점의 신뢰성에 문제가 있었다. 본인과 Claude의 채점 일치도가 20%로 낮았고, 재설명 채점 기준이 원래 계획(0~7점)에서 0~6점으로 변경되었으며, 비유 생성은 대표 15개 세션만 채점하였다. 넷째, 피험자가 LLM이므로 사람 학습자에게 일반화할 수 없으며, DeepSeek과 Gemini는 문헌 검증과 피험자 역할을 겸하였다. 다섯째, 자극 A와 B의 길이와 난이도가 완벽히 통제되지 않았다. 여섯째, Gemini의 재평가에서 자극 B에 핵심 정보 5가 누락되었고, 자극 A가 자극 B보다 63% 더 길며, 난이도 차이가 크다는 지적을 받았다. 본 논문 부록에는 정보 5를 추가하고 글자 수를 균형 있게 조정한 수정 자극을 수록하였으나, 본 실험은 수정 전 자극으로 수행되었다.

본 연구 결과는 후속 응용 연구에서 참고될 수 있다. LLM 기반 교육 도구 설계 시, 스토리텔링이 생성 과제에 부분적으로 유리하다는 점을 고려할 수 있다. 다만 이 결과를 사람 학습자에게 그대로 적용하지 않으며, 주 근거는 사람 대상 선행 연구이다.

5. 결론

본 연구는 LLM이 새로운 개념을 학습할 때 공식 중심 설명과 스토리 중심 설명의 효과를 비교하였다. ChatGPT, DeepSeek, Gemini를 대상으로 총 30회 실험을 수행한 결과, 가설이 예측한 응용 문제에서는 천장 효과로 검증되지 않았으나, 탐색적 분석에서 재설명과 비유 생성에서 스토리 중심 설명이 더 높은 점수를 보였다. 본 연구는 LLM의 개념 학습 메커니즘을 탐색하였다는 점에서 의의가 있다.

본 연구의 주요 발견은 세 가지이다. 첫째, 스토리텔링이 LLM의 생성 과제(재설명, 비유 생성)에 부분적으로 유리하였다. 둘째, 응용 문제에서는 천장 효과로 인해 자극 간 차이를 검증하지 못하였다. 셋째, LLM별 차이가 나타나 DeepSeek에서는 반대 결과가 확인되었다.

본 연구의 의의는 세 가지이다. 첫째, LLM의 개념 학습 메커니즘을 탐색하였다. 둘째, LLM 기반 교육 도구 설계에 시사점을 제공한다. 셋째, 사람과 LLM의 정보 처리 차이를 발견하였다.

후속 연구로 네 가지를 제안한다. 첫째, 사람 대상 실험을 통해 LLM 결과를 검증해야 한다. 둘째, 응용 문제의 난이도를 상향하여 천장 효과를 해결해야 한다. 셋째, 채점 기준을 명확히 하여 채점자 간 일치도를 향상시켜야 한다. 넷째, 더 다양한 LLM을 대상으로 견고성을 검증해야 한다.

참고문헌

Dahlstrom, M. F. (2014). Using narratives and storytelling to communicate science with nonexpert audiences. *Proceedings of the National Academy of Sciences*, 111(Supplement 4), 13614-13620. <https://doi.org/10.1073/pnas.1320645111>

Sclar, M., Choi, Y., Tsvetkov, Y., & Suhr, A. (2024). Quantifying Language Models' Sensitivity to Spurious Features in Prompt Design or: How I learned to start worrying about prompt formatting. *Proceedings of the 12th International Conference on Learning Representations (ICLR 2024)*. <https://arxiv.org/abs/2310.11324>

Sulmont, E., Patitsas, E., & Cooperstock, J. R. (2019). What is hard about teaching machine learning to non-majors? Insights from classifying instructors' learning goals. *ACM Transactions on Computing Education*, 19(4), 1-16. <https://doi.org/10.1145/3336124>

Tobler, S., Sinha, T., Köhler, K., & Kapur, M. (2024). Telling stories as preparation for learning: A Bayesian analysis of transfer performance and investigation of learning mechanisms. *Learning and Instruction*, 92, 101944. <https://doi.org/10.1016/j.learninstruc.2024.101944>

Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., Chi, E., Le, Q., & Zhou, D. (2022). Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. *Advances in Neural Information Processing Systems (NeurIPS 2022)*, 35, 24824-24837. <https://arxiv.org/abs/2201.11903>

재현 방법

재현 방법은 다음 다섯 부분으로 구성된다: 자극물, 프롬프트, 측정 도구, 채점 기준, 원자료 파일 목록. 자극 A와 B의 전문, 프롬프트 전문, 측정 도구 전문, 채점 기준 전문은 제출 패키지의 부록 파일에 포함하였다. 원자료는 30개 텍스트 파일(chatgpt_1.txt ~ gemini_10.txt)로 제출 패키지에 포함하였다.